

# Notas de Regresión Lineal Univariada

## Hojas 01 a 10

Carlos Leonardo

### Hoja 01: Introducción y función de costo

Modelo lineal univariado:

$$h_{\theta}(x) = \theta_0 + \theta_1 x$$

Función de costo:

$$J(\theta_0, \theta_1) = \frac{1}{2N} \sum_{i=1}^N \left( h_{\theta}(x^{(i)}) - y^{(i)} \right)^2$$

Objetivo: minimizar  $J(\theta_0, \theta_1)$

### Hoja 02: Derivadas parciales

Derivada de  $J$  respecto a  $\theta_0$ :

$$\frac{\partial J}{\partial \theta_0} = \frac{1}{2N} \sum_{i=1}^N 2(h_{\theta}(x^{(i)}) - y^{(i)}) = \frac{1}{N} \sum_{i=1}^N (h_{\theta}(x^{(i)}) - y^{(i)})$$

Derivada respecto a  $\theta_1$ :

$$\frac{\partial J}{\partial \theta_1} = \frac{1}{N} \sum_{i=1}^N (h_{\theta}(x^{(i)}) - y^{(i)}) x^{(i)}$$

### Hoja 03: Gradiente y vectorización

Descenso por gradiente:

$$\theta_j := \theta_j - \alpha \cdot \frac{\partial J}{\partial \theta_j}$$

Matriz de diseño:

$$X = \begin{bmatrix} 1 & x^{(1)} \\ 1 & x^{(2)} \\ \vdots & \vdots \\ 1 & x^{(N)} \end{bmatrix}, \quad y = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(N)} \end{bmatrix}$$

Predicciones:

$$h_{\theta} = X\theta$$

Costo vectorial:

$$J(\theta) = \frac{1}{2N} \|X\theta - y\|^2$$

## Hoja 04: Gradiente vectorial

$$\nabla_{\theta} J = \frac{1}{N} X^T (X\theta - y)$$

$$\theta := \theta - \alpha \cdot \frac{1}{N} X^T (X\theta - y)$$

## Hoja 05: Mínimos cuadrados

Minimizar:

$$J(\theta) = \frac{1}{2N} (X\theta - y)^T (X\theta - y)$$

$$\nabla_{\theta} J = \frac{1}{N} X^T (X\theta - y) \Rightarrow X^T X\theta = X^T y \Rightarrow \theta = (X^T X)^{-1} X^T y$$

## Hoja 06: Desarrollo de la derivada

Expandimos:

$$(X\theta - y)^T (X\theta - y) = \theta^T X^T X\theta - 2y^T X\theta + y^T y$$

Derivando:

$$\nabla_{\theta} J = \frac{1}{2N} (2X^T X\theta - 2X^T y) = \frac{1}{N} X^T (X\theta - y)$$

## Hoja 07: Geometría de la función

-  $J(\theta)$  es convexa - Tiene un mínimo global - El gradiente apunta hacia la dirección de mayor incremento

## Hoja 08: Ejemplo de iteración

$$\theta := \theta - \alpha \cdot \nabla_{\theta} J$$

Para un punto específico, se puede usar:

$$\theta_0 := \theta_0 - \alpha(h_{\theta}(x^{(i)}) - y^{(i)})$$

$$\theta_1 := \theta_1 - \alpha(h_{\theta}(x^{(i)}) - y^{(i)})x^{(i)}$$

## Hoja 09: Interpretación geométrica

La dirección del gradiente indica cómo ajustar los parámetros para minimizar el error. El mínimo se alcanza cuando  $\nabla_{\theta} J = 0$

## Hoja 10: Gradiente completo en forma matricial

$$J(\theta) = \frac{1}{2N}(X\theta - y)^T(X\theta - y) \quad \Rightarrow \quad \nabla_{\theta} J = \frac{1}{N}X^T(X\theta - y)$$