

Notas sobre Regresión Lineal y Logística

Carlos

April 24, 2025

Contents

1	Regresión Logística: Log-verosimilitud y derivadas	2
2	Derivación recursiva del gradiente	2
3	Regresión Lineal	2
3.1	Historia	2
3.2	Modelo de Regresión Lineal	2
3.3	Regresión Polinomial	3
4	Estimaciones con modelo lineal centrado	3
5	Evaluación del modelo lineal	3
5.1	F-test	3
5.2	t-test	3
6	Fundamentos de la Regresión Logística	3
7	Función logística y función logit	3
8	Log-verosimilitud y derivadas	4
9	Regularización	4
10	Desviación	4
11	Newton-Raphson	4
12	WLS y función cuadrática	4

1 Regresión Logística: Log-verosimilitud y derivadas

La log-verosimilitud para la regresión logística está dada por:

$$\ell(\boldsymbol{\theta}) = \sum_{i=1}^N y^{(i)} \log \sigma(\boldsymbol{\theta}^T \mathbf{x}^{(i)}) + (1 - y^{(i)}) \log(1 - \sigma(\boldsymbol{\theta}^T \mathbf{x}^{(i)}))$$

Antes de calcular la derivada, recordamos:

$$\sigma(z) = \frac{1}{1 + e^{-z}} \quad \text{y} \quad \frac{d}{dz} \sigma(z) = \sigma(z)(1 - \sigma(z))$$

La derivada de la log-verosimilitud con respecto a θ_j es:

$$\frac{\partial \ell(\boldsymbol{\theta})}{\partial \theta_j} = \sum_{i=1}^N [y^{(i)} - \sigma(\boldsymbol{\theta}^T \mathbf{x}^{(i)})] x_j^{(i)}$$

2 Derivación recursiva del gradiente

Esta fórmula se utiliza para construir el vector gradiente necesario en algoritmos como descenso del gradiente:

$$\nabla_{\boldsymbol{\theta}} \ell(\boldsymbol{\theta}) = \sum_{i=1}^N [y^{(i)} - \sigma(\boldsymbol{\theta}^T \mathbf{x}^{(i)})] \mathbf{x}^{(i)}$$

3 Regresión Lineal

3.1 Historia

Sir Francis Galton sugirió el concepto de regresión lineal en 1894.

3.2 Modelo de Regresión Lineal

Regresión lineal simple:

$$y = \beta_0 + \beta_1 x + \xi$$

Regresión lineal multivariada:

$$y = \sum_{i=1}^d \beta_i x_i, \quad x_0 = 1$$

En forma matricial:

$$\boldsymbol{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

3.3 Regresión Polinomial

El modelo polinomial tiene la forma:

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \cdots + \beta_n x^n + \xi$$

Usamos mínimos cuadrados para estimar los coeficientes minimizando:

$$\arg \min_{\beta_0, \beta_1} \sum_i [y_i - (\beta_0 + \beta_1 x_i)]^2$$

4 Estimaciones con modelo lineal centrado

Si usamos:

$$y_i = \beta_0^* + \beta_1(x_i - \bar{x}) + \varepsilon_i$$

entonces se obtiene:

$$\beta_0 = \bar{y}, \quad \beta_1 = \frac{S_{xy}}{S_{xx}}$$

5 Evaluación del modelo lineal

5.1 F-test

$$F = \frac{\sum(\hat{y}_i - \bar{y})^2 / (m - 1)}{\sum(y_i - \hat{y}_i)^2 / (n - m)} \sim F_{(m-1, n-m)}$$

5.2 t-test

$$t_j = \frac{\hat{\beta}_j}{\sqrt{C_{jj} \frac{\sum(y_i - \hat{y}_i)^2}{n - m}}}$$

6 Fundamentos de la Regresión Logística

Sea $\mathbf{X} \in \mathbb{R}^{n \times d}$, y vector binario:

$$P(y_i = 1) = p_i, \quad \mathbb{E}[y_i] = p_i = \mathbf{x}_i^T \boldsymbol{\beta}, \quad \text{Var}(y_i) = p_i(1 - p_i)$$

7 Función logística y función logit

$$p_i = \frac{e^{\mathbf{x}_i^T \boldsymbol{\beta}}}{1 + e^{\mathbf{x}_i^T \boldsymbol{\beta}}} \quad \text{y} \quad \eta_i = \log\left(\frac{p_i}{1 - p_i}\right) = \mathbf{x}_i^T \boldsymbol{\beta}$$

8 Log-verosimilitud y derivadas

$$\ell(\boldsymbol{\beta}) = \sum [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)]$$

$$\nabla_{\boldsymbol{\beta}} \ell(\boldsymbol{\beta}) = \mathbf{X}^T (\mathbf{y} - \mathbf{p})$$

$$\nabla_{\boldsymbol{\beta}}^2 \ell(\boldsymbol{\beta}) = -\mathbf{X}^T \mathbf{V} \mathbf{X}, \quad \text{donde } \mathbf{V} = \text{diag}(p_i(1 - p_i))$$

9 Regularización

$$\ell(\boldsymbol{\beta}) - \frac{\lambda}{2} \|\boldsymbol{\beta}\|^2$$

10 Desviación

$$DEV(\hat{\boldsymbol{\beta}}) = -2 \ln L(\hat{\boldsymbol{\beta}})$$

11 Newton-Raphson

$$\boldsymbol{\beta}^{(c+1)} = (\mathbf{X}^T \mathbf{V} \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^T \mathbf{V} \mathbf{Z}^{(c)}$$

12 WLS y función cuadrática

La estimación WLS consiste en minimizar:

$$\frac{1}{2} \boldsymbol{\beta}^T (\mathbf{X}^T \mathbf{V} \mathbf{X} + \lambda \mathbf{I}) \boldsymbol{\beta} - \boldsymbol{\beta}^T (\mathbf{X}^T \mathbf{V} \mathbf{Z}^{(c)})$$