

Integración de Aprendizaje Automático en Sistemas de Colas con Encuestas: Un Enfoque desde las Matemáticas Aplicadas

Carlos [Tu Apellido]

Abril 2025

Resumen

Resumen Extendido: La presente propuesta doctoral se centra en el desarrollo de una teoría unificada que integre modelos estocásticos de sistemas de colas, particularmente aquellos del tipo polling systems, con algoritmos de aprendizaje automático (Machine Learning, ML). El objetivo central es formular, analizar y validar modelos matemáticos que permitan optimizar políticas de servicio en entornos dinámicos, utilizando técnicas de ML como el Aprendizaje por Refuerzo. Esta integración pretende superar las limitaciones de los modelos clásicos, adaptándose en tiempo real a cambios en el entorno y mejorando el rendimiento en medidas como el tiempo de espera y el throughput. El proyecto contempla tanto una base teórica rigurosa, sustentada en cadenas de Markov y procesos semi-Markov, como una implementación computacional basada en simulaciones. Se espera que los resultados contribuyan al campo de las matemáticas aplicadas y a *data-driven systems* en áreas como telecomunicaciones, manufactura y logística.

1. Introducción

La teoría de colas y los sistemas de encuestas (*polling systems*) han sido pilares en el análisis de sistemas estocásticos con aplicaciones en redes de telecomunicaciones, manufactura, logística, entre otros. Sin embargo, estos modelos tradicionales muchas veces descansan sobre supuestos estacionarios o determinísticos que los hacen poco adaptables a ambientes reales, altamente dinámicos.

Por otro lado, el Aprendizaje Automático (*Machine Learning, ML*) ha demostrado ser eficaz para aprender patrones y tomar decisiones bajo incertidumbre en tiempo real. Esta investigación propone una integración formal entre la teoría de colas —en particular los *polling systems*— y técnicas modernas de ML, incluyendo el Aprendizaje por Refuerzo, con el objetivo de desarrollar una teoría unificada que permita modelar, analizar y optimizar estos sistemas.

2. Justificación

Existe una brecha significativa en la literatura sobre cómo utilizar ML para optimizar el comportamiento de sistemas de colas multi-servidor o multi-cliente. Si bien se han

explorado algunos enfoques empíricos, no hay una teoría unificada que combine la estructura matemática rigurosa de los modelos de colas con la flexibilidad adaptativa del aprendizaje automático. Esta propuesta se ubica en el cruce entre matemáticas aplicadas, ciencia de datos y optimización, con potencial para generar contribuciones significativas tanto teóricas como aplicadas.

3. Objetivos

Objetivo General

Desarrollar modelos matemáticos y computacionales que integren Aprendizaje Automático en sistemas de colas con encuestas, y analizar rigurosamente su desempeño.

Objetivos Específicos

- Formular modelos estocásticos que integren decisiones aprendidas mediante ML en sistemas de tipo *polling*.
- Analizar la estabilidad, convergencia y comportamiento asintótico de los modelos propuestos.
- Comparar el rendimiento de las políticas aprendidas frente a las clásicas como *round-robin*, *gated*, y *exhaustive*.
- Validar los resultados mediante simulación numérica y experimentos computacionales.

4. Hipótesis

- **H1:** Es posible construir un modelo matemático híbrido entre teoría de colas y aprendizaje automático que preserve la estabilidad del sistema bajo ciertas condiciones.
- **H2:** Las políticas de servicio aprendidas mediante ML superan en eficiencia (tiempo de espera, *throughput*) a las políticas estáticas tradicionales en entornos dinámicos.

5. Metodología

1. Revisión bibliográfica detallada sobre teoría de colas, *polling systems*, y Aprendizaje por Refuerzo.
2. Construcción de modelos estocásticos basados en cadenas de Markov, procesos semi-Markov o redes de colas.
3. Implementación de algoritmos de aprendizaje (supervisado/no supervisado/refuerzo) para aprendizaje de políticas.
4. Simulación computacional usando Python/R y librerías como `simpy`, `tensorflow`, `keras`.
5. Análisis matemático de estabilidad, condiciones de ergodicidad y convergencia.

6. Resultados Esperados

- Desarrollo de una teoría unificada que articule aprendizaje y sistemas estocásticos de colas.
- Artículos publicables en revistas de matemáticas aplicadas, ciencia de datos y teoría de colas.
- Herramientas de simulación de utilidad para ingeniería, logística o telecomunicaciones.

7. Cronograma Tentativo

Fase	Duración
Revisión bibliográfica	Mes 1 - Mes 3
Modelado matemático inicial	Mes 4 - Mes 6
Desarrollo de algoritmos ML	Mes 7 - Mes 9
Simulaciones y experimentación	Mes 10 - Mes 12
Análisis teórico y validación	Mes 13 - Mes 15
Redacción de artículos y tesis	Mes 16 - Mes 18

8. Antecedentes Teóricos

- **Teoría de Colas:** Modelos M/M/1, G/G/1, redes de colas de Jackson.
- **Polling Systems:** Políticas de servicio cíclicas, prioridades, colas con interrupciones.
- **Machine Learning:** Aprendizaje supervisado, no supervisado y por refuerzo.
- **Integración ML + Colas:** Modelos híbridos recientes en redes y data centers.

9. Bibliografía Inicial

- Kleinrock, L. *Queueing Systems, Volume 1: Theory*. Wiley-Interscience.
- Sutton, R. S., & Barto, A. G. *Reinforcement Learning: An Introduction*.
- Chen, H. & Yao, D. D. *Fundamentals of Queueing Networks: Performance, Asymptotics, and Optimization*.
- Zhou, Z. et al. (2020). "Queueing Theory Meets Deep Learning".
- Artículos recientes en IEEE, Springer y MDPI sobre ML y sistemas de colas.